

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет информатики, математики и компьютерных наук

Программа подготовки бакалавров по направлению
01.03.02 Прикладная математика и информатика

Антонов Илья Витальевич

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Проверка условной независимости в трехмерном распределении Бернулли

Рецензент

д.ф.-м.н., проф.

В. А. Калягин

Научный руководитель

д.ф.-м.н., проф.

П. А. Колданов

Нижний Новгород, 2024

Содержание

Введение	3
1 Теоретическая часть	5
1.1 Условная независимость в трехмерном распределении Бернулли	5
1.2 Частный коэффициент корреляции Пирсона в трехмерном распределении Бернулли	7
1.3 Тест на частный коэффициент корреляции Пирсона в трехмерном нормальном распределении	10
1.4 Тест проверки достаточного условия условной зависимости всех пар случайных величин в трехмерном распределении Бернулли	11
1.5 РНМН тест проверки независимости в двумерном распределении Бернулли	15
1.6 Процедура проверки условной независимости в трехмерном распределении Бернулли	16
2 Экспериментальная часть	18
2.1 Способ вычисления вероятностей для РНМН теста на ЭВМ	18
2.2 Анализ свойств построенных тестов	19
Заключение	23
Список литературы	24

Введение

Обзор по теме исследования и актуальность В современных задачах биоинформатики, информационного поиска, обработки речи и изображений возникает необходимость изучения взаимосвязей между большим количеством случайных величин. Методологию для решения такой проблемы предоставляют графические модели. Графической моделью [7] называется семейство вероятностных распределений, определенное в терминах ориентированного или неориентированного графа. В этом графе вершины соответствуют случайным величинам, а ребра отображают некоторые условные зависимости. Основным назначением графических моделей является создание аппарата, упрощающего вычисление совместных, маргинальных и условных вероятностей.

Наиболее известной графической моделью является гауссовская графическая модель [1], в которой рассматриваемые случайные величины имеют многомерное нормальное распределение. Процедуры идентификации гауссовской графической модели по наблюдениям приводятся в работах [5; 6]. Однако, эти процедуры оказываются неустойчивыми к отклонению от многомерного нормального распределения. В частности, при таком отклонении тесты проверки индивидуальных гипотез не контролируют уровень значимости. Кроме того, многомерное нормальное распределение не всегда является адекватной моделью для описания реальных данных. Поэтому проблема построения устойчивой графической модели является актуальной.

Направление построения устойчивой графической модели для произвольного случайного вектора $(X_1, \dots, X_N)^T$ целесообразно связать с построением графической модели для индикаторных случайных величин $(I_1, \dots, I_N)^T$, где $I_i = I(a_i < X_i < b_i)$. Возможной графической моделью в таком случае можно назвать 0-1 модель [12]. В ней ребро между вершинами, которые соответствуют случайным величинам I_i и I_j , проводится, если выполнены следующие условия:

- I_i и I_j маргинально зависимы
- I_i и I_j условно зависимы при условии I_k для всех $k \in \{1, \dots, N\} \setminus \{i, j\}$

Так как совместное распределение индикаторных случайных величинам описывается многомерным распределением Бернулли [4; 11], то для идентификации 0-1 модели по наблюдениям требуется теория проверки условной независимости в трехмерном распределении Бернулли. Построению требуемой теории посвящена данная работа.

Постановка задачи Задачей настоящей выпускной квалификационной работы является построение тестов уровня α проверки гипотезы

$H : X \perp\!\!\!\perp Y \mid Z$ по наблюдениям $\begin{pmatrix} x_1 \\ y_1 \\ z_1 \end{pmatrix}, \begin{pmatrix} x_2 \\ y_2 \\ z_2 \end{pmatrix}, \dots, \begin{pmatrix} x_n \\ y_n \\ z_n \end{pmatrix}$ над случайным вектором $(X, Y, Z)^T$ с трехмерным распределением Бернулли, а также анализ свойств этих тестов.

1 Теоретическая часть

1.1 Условная независимость в трехмерном распределении Бернулли

Определим трехмерное распределение Бернулли [4; 11].

Определение 1.1.1. *Случайный вектор $(X, Y, Z)^T$ имеет трехмерное распределение Бернулли, если множество его возможных значений:*

$$\begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \dots, \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$$

и заданы $P(X = x, Y = y, Z = z) = p_{xyz} \geq 0$, $\sum_{x=0}^1 \sum_{y=0}^1 \sum_{z=0}^1 p_{xyz} = 1$.

В настоящей работе будут рассматриваться только случайные векторы $(X, Y, Z)^T$, в которых $p_{xyz} > 0$ при всех $x \in \{0, 1\}$, $y \in \{0, 1\}$, $z \in \{0, 1\}$.

Приведем определение понятия условной независимости [8].

Определение 1.1.2. *Пусть $(X, Y, Z)^T$ – дискретный случайный вектор. Говорят, что случайные величины X и Y условно независимы при условии Z , и пишут $X \perp\!\!\!\perp Y \mid Z$, если:*

$$P(X = x, Y = y \mid Z = z) = P(X = x \mid Z = z)P(Y = y \mid Z = z)$$

при любых x, y и z для которого $P(Z = z) > 0$.

Сформулируем критерий условной независимости в трехмерном распределении Бернулли.

Теорема 1.1.1. *Пусть $(X, Y, Z)^T$ – случайный вектор, имеющий трехмерное распределение Бернулли, в котором $0 < P(Z = 0) < 1$. Случайные величины X и Y условно независимы при условии Z тогда и только тогда, когда*

$$p_{00z}p_{11z} = p_{01z}p_{10z}$$

для всех $z \in \{0, 1\}$.

Доказательство. Пусть $X \perp\!\!\!\perp Y \mid Z$. Значит, для любых $x \in \{0, 1\}$, $y \in \{0, 1\}$ и $z \in \{0, 1\}$ выполнено условие:

$$P(X = x, Y = y \mid Z = z) = P(X = x \mid Z = z)P(Y = y \mid Z = z) \quad (1.1.1)$$

После домножения (1.1.1) на $P(Z = z)^2 > 0$ получаем эквивалентное условие:

$$P(X = x, Y = y, Z = z)P(Z = z) = P(X = x, Z = z)P(Y = y, Z = z) \quad (1.1.2)$$

Найдем следующие вероятности:

$$P(X = x, Z = z) = p_{x0z} + p_{x1z}, \quad P(Y = y, Z = z) = p_{0yz} + p_{1yz}$$

$$P(Z = z) = p_{00z} + p_{01z} + p_{10z} + p_{11z}$$

Тогда условие (1.1.2) перепишем в следующем виде:

$$p_{xyz}(p_{00z} + p_{01z} + p_{10z} + p_{11z}) = (p_{x0z} + p_{x1z})(p_{0yz} + p_{1yz})$$

Это условие выполняется для всех $x \in \{0, 1\}$, $y \in \{0, 1\}$, $z \in \{0, 1\}$. Пусть z фиксировано. Если $x = 0$ и $y = 0$, то:

$$p_{00z}(p_{00z} + p_{01z} + p_{10z} + p_{11z}) = (p_{00z} + p_{01z})(p_{00z} + p_{10z}) \Leftrightarrow p_{00z}p_{11z} = p_{01z}p_{10z}$$

Если $x = 0$ и $y = 1$, то:

$$p_{01z}(p_{00z} + p_{01z} + p_{10z} + p_{11z}) = (p_{00z} + p_{01z})(p_{01z} + p_{11z}) \Leftrightarrow p_{00z}p_{11z} = p_{01z}p_{10z}$$

Если $x = 1$ и $y = 0$, то:

$$p_{10z}(p_{00z} + p_{01z} + p_{10z} + p_{11z}) = (p_{10z} + p_{11z})(p_{00z} + p_{10z}) \Leftrightarrow p_{00z}p_{11z} = p_{01z}p_{10z}$$

Если $x = 1$ и $y = 1$, то:

$$p_{11z}(p_{00z} + p_{01z} + p_{10z} + p_{11z}) = (p_{10z} + p_{11z})(p_{01z} + p_{11z}) \Leftrightarrow p_{00z}p_{11z} = p_{01z}p_{10z}$$

Таким образом, из $X \perp\!\!\!\perp Y \mid Z$ следует $p_{00z}p_{11z} = p_{01z}p_{10z}$ для всех $z \in \{0, 1\}$.

Поскольку в вышеприведенных рассуждениях все переходы равносильные, мы также доказали, что из условия $p_{00z}p_{11z} = p_{01z}p_{10z}$ для всех $z \in \{0, 1\}$ следует $X \perp\!\!\!\perp Y \mid Z$. \square

Покажем, что существует случайный вектор $(X, Y, Z)^T$ с трехмерным распределением Бернулли, в котором $X \perp\!\!\!\perp Y \mid Z$.

Пример 1.1.1. Пусть $(X, Y, Z)^T$ имеет трехмерное распределение Бернулли с вероятностями $p_{000} = 0.15$, $p_{001} = 0.1$, $p_{010} = 0.3$, $p_{011} = 0.1$, $p_{100} = 0.05$, $p_{101} = 0.1$, $p_{110} = 0.1$, $p_{111} = 0.1$. Заметим, что:

$$p_{000}p_{110} = p_{010}p_{100} = 0.015$$

$$p_{001}p_{111} = p_{011}p_{101} = 0.01$$

Следовательно из [теор. 1.1.1](#) следует, что $X \perp\!\!\!\perp Y \mid Z$.

1.2 Частный коэффициент корреляции Пирсона в трехмерном распределении Бернулли

В данном разделе исследуем свойства частного коэффициента корреляции Пирсона в трехмерном распределении Бернулли.

Для случайного вектора $(X, Y, Z)^T$ определим ковариационную матрицу:

$$\Sigma = \begin{pmatrix} \sigma_{XX} & \sigma_{XY} & \sigma_{XZ} \\ \sigma_{YX} & \sigma_{YY} & \sigma_{YZ} \\ \sigma_{ZX} & \sigma_{ZY} & \sigma_{ZZ} \end{pmatrix}$$

где $\sigma_{XY} = E((X - EX)(Y - EY))$. Остатками от X и Y при регрессии на Z называются случайные величины:

$$X' = (X - EX) - \frac{\sigma_{XZ}}{\sigma_{ZZ}}(Z - EZ)$$

$$Y' = (Y - EY) - \frac{\sigma_{YZ}}{\sigma_{ZZ}}(Z - EZ)$$

Согласно работе [3], частный коэффициент корреляции Пирсона определяется как коэффициент корреляции Пирсона между остатками, другими словами:

$$\rho^{XY \cdot Z} = \frac{E(X'Y')}{\sqrt{E(X'^2)E(Y'^2)}}$$

Приведем соотношения, которые справедливы для $\rho^{XY \cdot Z}$ в произвольном распределении.

Лемма 1.2.1. Пусть $(X, Y, Z)^T$ – произвольный случайный вектор, имеющий вторые моменты. Тогда:

$$\rho^{XY \cdot Z} = \frac{\sigma_{XY}\sigma_{ZZ} - \sigma_{XZ}\sigma_{YZ}}{\sqrt{\sigma_{XX}\sigma_{ZZ} - \sigma_{XZ}^2}\sqrt{\sigma_{YY}\sigma_{ZZ} - \sigma_{YZ}^2}} = \frac{\rho_{XY} - \rho_{XZ}\rho_{YZ}}{\sqrt{1 - \rho_{XZ}^2}\sqrt{1 - \rho_{YZ}^2}}$$

где $\rho_{XY} = \frac{\sigma_{XY}}{\sqrt{\sigma_{XX}\sigma_{YY}}}$.

Доказательство.

$$\begin{aligned} E(X'Y') &= E(((X - EX) - \frac{\sigma_{XZ}}{\sigma_{ZZ}}(Z - EZ))((Y - EY) - \frac{\sigma_{YZ}}{\sigma_{ZZ}}(Z - EZ))) = \\ &= \sigma_{XY} - \frac{\sigma_{YZ}}{\sigma_{ZZ}}\sigma_{XZ} - \frac{\sigma_{XZ}}{\sigma_{ZZ}}\sigma_{YZ} + \frac{\sigma_{XZ}\sigma_{YZ}}{\sigma_{ZZ}\sigma_{ZZ}}\sigma_{ZZ} = \frac{\sigma_{XY}\sigma_{ZZ} - \sigma_{XZ}\sigma_{YZ}}{\sigma_{ZZ}} \end{aligned}$$

Тогда:

$$\begin{aligned} \rho^{XY \cdot Z} &= \frac{E(X'Y')}{\sqrt{E(X'^2)E(Y'^2)}} = \frac{\frac{\sigma_{XY}\sigma_{ZZ} - \sigma_{XZ}\sigma_{YZ}}{\sigma_{ZZ}}}{\sqrt{\frac{\sigma_{XX}\sigma_{ZZ} - \sigma_{XZ}^2}{\sigma_{ZZ}}}\sqrt{\frac{\sigma_{YY}\sigma_{ZZ} - \sigma_{YZ}^2}{\sigma_{ZZ}}}} = \\ &= \frac{\sigma_{XY}\sigma_{ZZ} - \sigma_{XZ}\sigma_{YZ}}{\sqrt{\sigma_{XX}\sigma_{ZZ} - \sigma_{XZ}^2}\sqrt{\sigma_{YY}\sigma_{ZZ} - \sigma_{YZ}^2}} = \\ &= \frac{\sigma_{ZZ}\sqrt{\sigma_{XX}\sigma_{YY}}\left(\frac{\sigma_{XY}}{\sqrt{\sigma_{XX}\sigma_{YY}}} - \frac{\sigma_{XZ}}{\sqrt{\sigma_{XX}\sigma_{ZZ}}}\frac{\sigma_{YZ}}{\sqrt{\sigma_{YY}\sigma_{ZZ}}}\right)}{\sqrt{\sigma_{XX}\sigma_{ZZ} - \sigma_{XZ}^2}\sqrt{\sigma_{YY}\sigma_{ZZ} - \sigma_{YZ}^2}} = \\ &= \frac{\rho_{XY} - \rho_{XZ}\rho_{YZ}}{\sqrt{1 - \frac{\sigma_{XZ}^2}{\sigma_{XX}\sigma_{ZZ}}}\sqrt{1 - \frac{\sigma_{YZ}^2}{\sigma_{YY}\sigma_{ZZ}}}} = \frac{\rho_{XY} - \rho_{XZ}\rho_{YZ}}{\sqrt{1 - \rho_{XZ}^2}\sqrt{1 - \rho_{YZ}^2}} \end{aligned}$$

□

Для дальнейших рассуждений используем следующие обозначения:

$$p_{x**} = P(X = x), \quad p_{*y*} = P(Y = y), \quad p_{**z} = P(Z = z)$$

$$p_{xy*} = P(X = x, Y = y), \quad p_{x*z} = P(X = x, Z = z), \quad p_{*yz} = P(Y = y, Z = z)$$

Найдем значение выражения $\sigma_{XY}\sigma_{ZZ} - \sigma_{XZ}\sigma_{YZ}$ в трехмерном распределении Бернулли.

Лемма 1.2.2. Пусть $(X, Y, Z)^T$ – случайный вектор, имеющий трехмерное распределение Бернулли. Тогда:

$$\sigma_{XY}\sigma_{ZZ} - \sigma_{XZ}\sigma_{YZ} = p_{**0}(p_{001}p_{111} - p_{011}p_{101}) + p_{**1}(p_{000}p_{110} - p_{010}p_{100})$$

Доказательство. Легко проверить, что $\sigma_{ZZ} = p_{**1}(1 - p_{**1})$. Найдем соотношение для σ_{XY} . Воспользуемся формулой $\sigma_{XY} = E(XY) - E(X)E(Y)$.

$$E(XY) = 1 \cdot p_{11*} + 0 \cdot (p_{00*} + p_{01*} + p_{10*}) = p_{11*}$$

Таким образом, $\sigma_{XY} = p_{11*} - p_{1**}p_{*1*}$. Аналогично, $\sigma_{XZ} = p_{1*1} - p_{1**}p_{**1}$ и $\sigma_{YZ} = p_{*11} - p_{*1*}p_{**1}$. Преобразуем выражение $\sigma_{XY}\sigma_{ZZ} - \sigma_{XZ}\sigma_{YZ} =$

$$\begin{aligned} &= (p_{11*} - p_{1**}p_{*1*})p_{**1}(1 - p_{**1}) - (p_{1*1} - p_{1**}p_{**1})(p_{*11} - p_{*1*}p_{**1}) = \\ &= p_{11*}p_{**1} - p_{11*}p_{**1}p_{**1} - p_{1**}p_{*1*}p_{**1} - p_{1*1}p_{*11} + p_{1*1}p_{*1*}p_{**1} + p_{1**}p_{**1}p_{*11} = \\ &= (p_{111}p_{**1} + p_{110}p_{**1}) - p_{11*}p_{**1}p_{**1} - p_{1**}p_{*1*}p_{**1} - \\ &\quad - p_{1*1}p_{*11} + p_{1*1}p_{*1*}p_{**1} + p_{1**}p_{**1}p_{*11} = \\ &= (p_{111}p_{**1} - p_{1*1}p_{*11}) + p_{**1}(p_{110} - p_{11*}p_{**1} - p_{1**}p_{*1*} + p_{1*1}p_{*1*} + p_{1**}p_{*11}) \quad (1.2.1) \end{aligned}$$

Заметим, что:

1. $p_{110} - p_{11*}p_{**1} = p_{110} - p_{110}p_{**1} - p_{111}p_{**1} = p_{110}(1 - p_{**1}) - p_{111}p_{**1} =$
 $= p_{110}p_{**0} - p_{111}p_{**1}$
2. $-p_{1**}p_{*1*} + p_{1*1}p_{*1*} + p_{1**}p_{*11} = -(p_{1*0} + p_{1*1})(p_{*10} + p_{*11}) + p_{1*1}(p_{*10} + p_{*11}) +$
 $+ (p_{1*0} + p_{1*1})p_{*11} = -p_{1*0}p_{*10} + p_{1*1}p_{*11}$

Учитывая вышеприведенные соотношения, запишем (1.2.1):

$$\begin{aligned} &(p_{111}p_{**1} - p_{1*1}p_{*11}) + p_{**1}((p_{110}p_{**0} - p_{1*0}p_{*10}) - (p_{111}p_{**1} - p_{1*1}p_{*11})) = \\ &= (1 - p_{**1})(p_{111}p_{**1} - p_{1*1}p_{*11}) + p_{**1}(p_{110}p_{**0} - p_{1*0}p_{*10}) = \\ &= p_{**0}(p_{111}p_{**1} - p_{1*1}p_{*11}) + p_{**1}(p_{110}p_{**0} - p_{1*0}p_{*10}) \quad (1.2.2) \end{aligned}$$

Также заметим, что:

$$\begin{aligned} p_{11z}p_{**z} - p_{1*z}p_{*1z} &= p_{11z}(p_{00z} + p_{01z} + p_{10z} + p_{11z}) - (p_{10z} + p_{11z})(p_{01z} + p_{11z}) = \\ &= p_{00z}p_{11z} - p_{01z}p_{10z}. \end{aligned}$$

Тогда в (1.2.2) имеем:

$$\sigma_{XY}\sigma_{ZZ} - \sigma_{XZ}\sigma_{YZ} = p_{**0}(p_{001}p_{111} - p_{011}p_{101}) + p_{**1}(p_{000}p_{110} - p_{010}p_{100})$$

□

Вышеприведенное соотношение для $\sigma_{XY}\sigma_{ZZ} - \sigma_{XZ}\sigma_{YZ}$ позволяет доказать следующую теорему.

Теорема 1.2.1. Пусть $(X, Y, Z)^T$ – случайный вектор, имеющий трехмерное распределение Бернулли. Если $X \perp\!\!\!\perp Y \mid Z$, то $\rho^{XY \cdot Z} = 0$.

Доказательство. Пусть $X \perp\!\!\!\perp Y \mid Z$. Тогда по [теор. 1.1.1](#): $p_{000}p_{110} = p_{010}p_{100}$ и $p_{001}p_{111} = p_{011}p_{101}$. Используя [лемм. 1.2.2](#), имеем:

$$\sigma_{XY}\sigma_{ZZ} - \sigma_{XZ}\sigma_{YZ} = p_{**0}(p_{001}p_{111} - p_{011}p_{101}) + p_{**1}(p_{000}p_{110} - p_{010}p_{100}) = 0$$

Следовательно, $\rho^{XY \cdot Z} = 0$. □

В обратную сторону [теор. 1.2.1](#) неверна. Приведем контрпример.

Пример 1.2.1. Пусть $p_{000} = 0.15$, $p_{001} = 0.1$, $p_{010} = 0.1$, $p_{011} = 0.15$, $p_{100} = 0.1$, $p_{101} = 0.15$, $p_{110} = 0.15$, $p_{111} = 0.1$. Тогда $p_{**0} = 0.5$, $p_{**1} = 0.5$ и

$$\begin{aligned} \sigma_{XY}\sigma_{ZZ} - \sigma_{XZ}\sigma_{YZ} &= p_{**1}(p_{000}p_{110} - p_{010}p_{100}) + p_{**0}(p_{001}p_{111} - p_{011}p_{101}) = \\ &= 0.5 \cdot (0.15 \cdot 0.15 - 0.1 \cdot 0.1) + 0.5 \cdot (0.1 \cdot 0.1 - 0.15 \cdot 0.15) = 0 \end{aligned}$$

Следовательно $\rho^{XY \cdot Z} = 0$. Однако, случайные величины X и Y условно зависимы при условии Z поскольку:

$$p_{000}p_{110} - p_{010}p_{100} = 0.15 \cdot 0.15 - 0.1 \cdot 0.1 = 0.0125 \neq 0$$

$$p_{001}p_{111} - p_{011}p_{101} = 0.1 \cdot 0.1 - 0.15 \cdot 0.15 = -0.0125 \neq 0$$

Следствие 1.2.1. Из [теор. 1.2.1](#) непосредственно следует, что ненулевое значение частного коэффициента корреляции Пирсона $\rho^{XY \cdot Z}$ в трехмерном распределении Бернулли является достаточным условием условной зависимости X и Y при условии Z .

1.3 Тест на частный коэффициент корреляции Пирсона в трехмерном нормальном распределении

Пусть $(X, Y, Z)^T$ имеет трехмерное нормальное распределение,

а $\begin{pmatrix} x_1 \\ y_1 \\ z_1 \end{pmatrix}, \begin{pmatrix} x_2 \\ y_2 \\ z_2 \end{pmatrix}, \dots, \begin{pmatrix} x_n \\ y_n \\ z_n \end{pmatrix}$ реализация повторной выборки из распределения случайного вектора $(X, Y, Z)^T$.

Определение 1.3.1. Выборочным частным коэффициентом корреляции Пирсона называется

$$r^{XY \cdot Z} = \frac{r_{XY} - r_{XZ}r_{YZ}}{\sqrt{1 - r_{XZ}^2}\sqrt{1 - r_{YZ}^2}}$$

$$\text{где } r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}, \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i.$$

Известно [1], что в трехмерном нормальном распределении при истинности гипотезы $H^{\text{Partial}} : \rho^{XY \cdot Z} = 0$ статистика:

$$T^{\text{Partial}} = \sqrt{n-3} \frac{R^{XY \cdot Z}}{\sqrt{1 - (R^{XY \cdot Z})^2}}$$

имеет распределение Стьюдента с $n-3$ степенями свободы. Тогда тест уровня α проверки гипотезы $H^{\text{Partial}} : \rho^{XY \cdot Z} = 0$ против альтернативы $K^{\text{Partial}} : \rho^{XY \cdot Z} \neq 0$ имеет вид:

$$\varphi^{\text{Partial}}(t^{\text{Partial}}) = \begin{cases} 1, & |t^{\text{Partial}}| > C \\ 0, & |t^{\text{Partial}}| \leq C \end{cases}$$

где константа C удовлетворяет уравнению $P_{H^{\text{Partial}}}(T^{\text{Partial}} > C) = 1 - \alpha/2$.

1.4 Тест проверки достаточного условия условной зависимости всех пар случайных величин в трехмерном распределении Бернулли

Пусть $(X, Y, Z)^T$ имеет трехмерное распределение Бернулли, для которого $p_{xyz} > 0$ при всех $x \in \{0, 1\}$, $y \in \{0, 1\}$, $z \in \{0, 1\}$. Запишем данное распределение в экспоненциальной форме:

$$P(X = x, Y = y, Z = z) = p_{000}^{(1-x)(1-y)(1-z)} \dots p_{111}^{xyz} =$$

$$= \exp \left\{ \ln(p_{000}) + \ln \left(\frac{p_{001}p_{111}p_{010}p_{100}}{p_{011}p_{101}p_{000}p_{110}} \right) xyz + \ln \left(\frac{p_{100}}{p_{000}} \right) x + \ln \left(\frac{p_{010}}{p_{000}} \right) y + \right.$$

$$\left. + \ln \left(\frac{p_{001}}{p_{000}} \right) z + \ln \left(\frac{p_{000}p_{110}}{p_{010}p_{100}} \right) xy + \ln \left(\frac{p_{000}p_{101}}{p_{001}p_{100}} \right) xz + \ln \left(\frac{p_{000}p_{011}}{p_{001}p_{010}} \right) yz \right\}$$

Среди параметров, стоящих при статистиках xyz, x, y, z, xy, xz, yz , выделим параметр, связанный с условной независимостью.

Теорема 1.4.1. Пусть $(X, Y, Z)^T$ – случайный вектор, имеющий трехмерное распределение Бернулли, в котором $p_{xyz} > 0$ при всех $x \in \{0, 1\}$, $y \in \{0, 1\}$, $z \in \{0, 1\}$, и $\theta = \ln \left(\frac{p_{001}p_{111}p_{010}p_{100}}{p_{011}p_{101}p_{000}p_{110}} \right)$. Если выполнено хотя бы одно из условий:

- $X \perp\!\!\!\perp Y \mid Z$
- $X \perp\!\!\!\perp Z \mid Y$
- $Y \perp\!\!\!\perp Z \mid X$

то параметр θ принимает значение 0.

Доказательство. Результаты [теор. 1.1.1](#) можно обобщить следующим образом:

$$X \perp\!\!\!\perp Z \mid Y \Leftrightarrow p_{000}p_{101} = p_{001}p_{100} \text{ и } p_{010}p_{111} = p_{011}p_{110}$$

$$Y \perp\!\!\!\perp Z \mid X \Leftrightarrow p_{000}p_{011} = p_{001}p_{010} \text{ и } p_{100}p_{111} = p_{101}p_{110}$$

1. Пусть $X \perp\!\!\!\perp Y \mid Z$, тогда по [теор. 1.1.1](#) выполнено: $p_{000}p_{110} = p_{010}p_{100}$ и $p_{001}p_{111} = p_{011}p_{101}$. Отсюда следует, что $\theta = \ln(1) = 0$.
2. Пусть $X \perp\!\!\!\perp Z \mid Y$, тогда из вышеприведенного $p_{000}p_{101} = p_{001}p_{100}$ и $p_{010}p_{111} = p_{011}p_{110}$. Отсюда следует, что $\theta = \ln(1) = 0$.
3. Пусть $Y \perp\!\!\!\perp Z \mid X$, тогда из вышеприведенного $p_{000}p_{011} = p_{001}p_{010}$ и $p_{100}p_{111} = p_{101}p_{110}$. Отсюда следует, что $\theta = \ln(1) = 0$.

□

Следствие 1.4.1. Из [теор. 1.4.1](#) непосредственно следует, что ненулевое значение параметра $\theta = \ln \left(\frac{p_{001}p_{111}p_{010}p_{100}}{p_{011}p_{101}p_{000}p_{110}} \right)$ является достаточным условием условной зависимости всех пар случайных величин в трехмерном распределении Бернулли.

Пусть $\begin{pmatrix} x_1 \\ y_1 \\ z_1 \end{pmatrix}, \begin{pmatrix} x_2 \\ y_2 \\ z_2 \end{pmatrix}, \dots, \begin{pmatrix} x_n \\ y_n \\ z_n \end{pmatrix}$ реализация повторной выборки из рас-

пределения случайного вектора $(X, Y, Z)^T$. Совместное распределение повторной выборки имеет вид:

$$P(X_1 = x_1, Y_1 = y_1, Z_1 = z_1, \dots, X_n = x_n, Y_n = y_n, Z_n = z_n) =$$

$$\begin{aligned}
&= \prod_{i=1}^n P(X_i = x_i, Y_i = y_i, Z_i = z_i) = \\
&= \exp \left\{ \ln(p_{000})n + \ln \left(\frac{p_{001}p_{111}p_{010}p_{100}}{p_{011}p_{101}p_{000}p_{110}} \right) \sum_{i=1}^n x_i y_i z_i + \right. \\
&\quad + \ln \left(\frac{p_{100}}{p_{000}} \right) \sum_{i=1}^n x_i + \ln \left(\frac{p_{010}}{p_{000}} \right) \sum_{i=1}^n y_i + \ln \left(\frac{p_{001}}{p_{000}} \right) \sum_{i=1}^n z_i + \\
&\quad \left. + \ln \left(\frac{p_{000}p_{110}}{p_{010}p_{100}} \right) \sum_{i=1}^n x_i y_i + \ln \left(\frac{p_{000}p_{101}}{p_{001}p_{100}} \right) \sum_{i=1}^n x_i z_i + \ln \left(\frac{p_{000}p_{011}}{p_{001}p_{010}} \right) \sum_{i=1}^n y_i z_i \right\}
\end{aligned}$$

Обозначим

$$\begin{aligned}
u &= \sum_{i=1}^n x_i y_i z_i, \quad t_1 = \sum_{i=1}^n x_i y_i, \quad t_2 = \sum_{i=1}^n x_i z_i, \\
t_3 &= \sum_{i=1}^n y_i z_i, \quad t_4 = \sum_{i=1}^n x_i, \quad t_5 = \sum_{i=1}^n y_i, \quad t_6 = \sum_{i=1}^n z_i, \quad t = (t_1, \dots, t_6)
\end{aligned}$$

Согласно [9] РНМН тест уровня α проверки гипотезы $H^{\text{Theta}} : \theta = 0$ против альтернативы $K^{\text{Theta}} : \theta \neq 0$ имеет вид:

$$\varphi^{\text{Theta}}(u, t) = \begin{cases} 1, & u < C_1(t) \text{ или } u > C_2(t) \\ \gamma_i, & u = C_i(t), \quad i = 1, 2 \\ 0, & C_1(t) < u < C_2(t) \end{cases}$$

где константы $C_i(t)$ и $\gamma_i(t)$ определяются из системы уравнений:

$$\begin{cases} E_{\theta=0}(\varphi^{\text{Theta}}(U, T) \mid T = t) = \alpha \\ E_{\theta=0}(U \varphi^{\text{Theta}}(U, T) \mid T = t) = \alpha E_{\theta=0}(U \mid T = t) \end{cases}$$

Приведем распределение статистики U при условии $T = t$.

Лемма 1.4.1. Пусть $k_1(u) = u$, $k_2(u) = t_1 - u$, $k_3(u) = t_2 - u$, $k_4(u) = t_3 - u$, $k_5(u) = t_4 - t_1 - t_2 + u$, $k_6(u) = t_5 - t_1 - t_3 + u$, $k_7(u) = t_6 - t_2 - t_3 + u$, $k_8(u) = n - u + t_1 + t_2 + t_3 - t_4 - t_5 - t_6$. Тогда

$$P_{\theta=0}(U = u \mid T = t) = \frac{(\prod_{i=1}^8 k_i(u)!)^{-1}}{\sum_{s \in \mathcal{D}} (\prod_{i=1}^8 k_i(s)!)^{-1}}$$

где $\mathcal{D} = \{s \in \mathbb{Z} : 0 \leq k_i(s) \leq n \text{ для всех } i = 1 \dots, 8\}$.

Доказательство. Найдем совместное распределение статистик (U, T_1, \dots, T_6) :

$$\begin{aligned}
P(U = u, T = t) &= P(U = u, T_1 = t_1, T_2 = t_2, T_3 = t_3, T_4 = t_4, T_5 = t_5, T_6 = t_6) = \\
&= P\left(\sum_{i=1}^n X_i Y_i Z_i = u, \sum_{i=1}^n X_i Y_i = t_1, \sum_{i=1}^n X_i Z_i = t_2, \sum_{i=1}^n Y_i Z_i = t_3, \right. \\
&\quad \left. \sum_{i=1}^n X_i = t_4, \sum_{i=1}^n Y_i = t_5, \sum_{i=1}^n Z_i = t_6\right) = \\
&= P\left(\sum_{i=1}^n X_i Y_i Z_i = u, \sum_{i=1}^n X_i Y_i (1 - Z_i) = t_1 - u, \sum_{i=1}^n X_i (1 - Y_i) Z_i = t_2 - u, \right. \\
&\quad \sum_{i=1}^n (1 - X_i) Y_i Z_i = t_3 - u, \sum_{i=1}^n X_i (1 - Y_i) (1 - Z_i) = t_4 - t_1 - t_2 + u, \\
&\quad \sum_{i=1}^n (1 - X_i) Y_i (1 - Z_i) = t_5 - t_1 - t_3 + u, \sum_{i=1}^n (1 - X_i) (1 - Y_i) Z_i = t_6 - t_2 - t_3 + u, \\
&\quad \left. \sum_{i=1}^n (1 - X_i) (1 - Y_i) (1 - Z_i) = n - u + t_1 + t_2 + t_3 - t_4 - t_5 - t_6\right) = \frac{n!}{\prod_{i=1}^8 k_i(u)!} \times \\
&\quad \times p_{111}^u p_{110}^{t_1-u} p_{101}^{t_2-u} p_{011}^{t_3-u} p_{100}^{t_4-t_1-t_2+u} p_{010}^{t_5-t_1-t_3+u} p_{001}^{t_6-t_2-t_3+u} p_{000}^{n-u+t_1+t_2+t_3-t_4-t_5-t_6}
\end{aligned}$$

Тогда условное распределение статистики U при условии $T = t$ можно записать как:

$$\begin{aligned}
P(U = u \mid T = t) &= \frac{P(U = u, T = t)}{P(T = t)} = \frac{P(U = u, T = t)}{\sum_{s \in \mathcal{D}} P(U = s, T = t)} = \\
&= \frac{(\prod_{i=1}^8 k_i(u)!)^{-1} \left(\frac{p_{001} p_{010} p_{100} p_{111}}{p_{000} p_{011} p_{101} p_{110}} \right)^u}{\sum_{s \in \mathcal{D}} (\prod_{i=1}^8 k_i(s)!)^{-1} \left(\frac{p_{001} p_{010} p_{100} p_{111}}{p_{000} p_{011} p_{101} p_{110}} \right)^s}
\end{aligned}$$

При истинности гипотезы $\theta = 0$ справедливо равенство $\frac{p_{001} p_{010} p_{100} p_{111}}{p_{000} p_{011} p_{101} p_{110}} = 1$.

Следовательно:

$$P_{\theta=0}(U = u \mid T = t) = \frac{(\prod_{i=1}^8 k_i(u)!)^{-1}}{\sum_{s \in \mathcal{D}} (\prod_{i=1}^8 k_i(s)!)^{-1}}$$

□

1.5 РНМН тест проверки независимости в двумерном распределении Бернулли

Приведем определение случайного вектора с двумерным распределением Бернулли [4].

Определение 1.5.1. Случайный вектор $(X, Y)^T$ имеет двумерное распределение Бернулли, если множество его возможных значений:

$$\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

и заданы $P(X = x, Y = y) = p_{xy} \geq 0, \sum_{x=0}^1 \sum_{y=0}^1 p_{xy} = 1$.

Нами будут рассматриваться только случайные векторы $(X, Y)^T$ с двумерным распределением Бернулли, в которых $p_{xy} > 0$ при всех $x \in \{0, 1\}$, $y \in \{0, 1\}$. Запишем данное распределение в экспоненциальной форме:

$$\begin{aligned} P(X = x, Y = y) &= p_{00}^{(1-x)(1-y)} p_{01}^{(1-x)y} p_{10}^{x(1-y)} p_{11}^{xy} = \\ &= \exp \left\{ \ln(p_{00}) + \ln \left(\frac{p_{10}}{p_{00}} \right) x + \ln \left(\frac{p_{01}}{p_{00}} \right) y + \ln \left(\frac{p_{00}p_{11}}{p_{01}p_{10}} \right) xy \right\} \end{aligned}$$

Приведем теорему из работы [4].

Теорема 1.5.1. Пусть $(X, Y)^T$ имеет двумерное распределение Бернулли, в котором $p_{xy} > 0$ при всех $x \in \{0, 1\}$, $y \in \{0, 1\}$. X и Y независимы тогда и только тогда, когда $\theta = \ln \left(\frac{p_{00}p_{11}}{p_{01}p_{10}} \right) = 0$.

Пусть $\begin{pmatrix} x_1 \\ y_1 \end{pmatrix}, \begin{pmatrix} x_2 \\ y_2 \end{pmatrix}, \dots, \begin{pmatrix} x_n \\ y_n \end{pmatrix}$ реализация повторной выборки из распределения случайного вектора $(X, Y)^T$. Совместное распределение повторной выборки имеет вид:

$$\begin{aligned} P(X_1 = x_1, Y_1 = y_1, \dots, X_n = x_n, Y_n = y_n) &= \prod_{i=1}^n P(X_i = x_i, Y_i = y_i) = \\ &= \exp \left\{ \ln(p_{00})n + \ln \left(\frac{p_{10}}{p_{00}} \right) \sum_{i=1}^n x_i + \ln \left(\frac{p_{01}}{p_{00}} \right) \sum_{i=1}^n y_i + \ln \left(\frac{p_{00}p_{11}}{p_{01}p_{10}} \right) \sum_{i=1}^n x_i y_i \right\} \end{aligned}$$

Обозначим

$$u = \sum_{i=1}^n x_i y_i, \quad t_1 = \sum_{i=1}^n x_i, \quad t_2 = \sum_{i=1}^n y_i, \quad t = (t_1, t_2)$$

Согласно [9] РНМН тест уровня α проверки гипотезы $H^{\text{Independence}} : \theta = 0$ против альтернативы $K^{\text{Independence}} : \theta \neq 0$ имеет вид:

$$\varphi^{\text{Independence}}(u, t) = \begin{cases} 1, & u < C_1(t) \text{ или } u > C_2(t) \\ \gamma_i, & u = C_i(t), \quad i = 1, 2 \\ 0, & C_1(t) < u < C_2(t) \end{cases}$$

где константы $C_i(t)$ и $\gamma_i(t)$ определяются из системы уравнений:

$$\begin{cases} E_{\theta=0}(\varphi^{\text{Independence}}(U, T) \mid T = t) = \alpha \\ E_{\theta=0}(U \varphi^{\text{Independence}}(U, T) \mid T = t) = \alpha E_{\theta=0}(U \mid T = t) \end{cases}$$

Приведем распределение статистики U при условии $T = t$.

Лемма 1.5.1. Пусть $k_1(u) = u$, $k_2(u) = t_1 - u$, $k_3(u) = t_2 - u$, $k_4(u) = n - t_1 - t_2 + u$. Тогда

$$P_{\theta=0}(U = u \mid T = t) = \frac{(\prod_{i=1}^4 k_i(u)!)^{-1}}{\sum_{s \in \mathcal{D}} (\prod_{i=1}^4 k_i(s)!)^{-1}}$$

где $\mathcal{D} = \{s \in \mathbb{Z} : 0 \leq k_i(s) \leq n \text{ для всех } i = 1 \dots, 4\}$.

Доказательство [лемм. 1.5.1](#) не приводится, поскольку оно полностью аналогично доказательству [лемм. 1.4.1](#).

1.6 Процедура проверки условной независимости в трехмерном распределении Бернулли

Пусть $(X, Y, Z)^T$ – случайный вектор, имеющий трехмерное распределение Бернулли, а $\begin{pmatrix} x_1 \\ y_1 \\ z_1 \end{pmatrix}, \begin{pmatrix} x_2 \\ y_2 \\ z_2 \end{pmatrix}, \dots, \begin{pmatrix} x_n \\ y_n \\ z_n \end{pmatrix}$ реализация повторной выборки из распределения $(X, Y, Z)^T$.

Предложим процедуру проверки гипотезы $H : X \perp\!\!\!\perp Y \mid Z$, контролирующую вероятность ошибки первого рода на уровне α :

- Разобьем исходную выборку на две подвыборки:

$$\begin{pmatrix} x_{i_1} \\ y_{i_1} \\ 0 \end{pmatrix}, \begin{pmatrix} x_{i_2} \\ y_{i_2} \\ 0 \end{pmatrix}, \dots, \begin{pmatrix} x_{i_{n_0}} \\ y_{i_{n_0}} \\ 0 \end{pmatrix} \text{ и } \begin{pmatrix} x_{j_1} \\ y_{j_1} \\ 1 \end{pmatrix}, \begin{pmatrix} x_{j_2} \\ y_{j_2} \\ 1 \end{pmatrix}, \dots, \begin{pmatrix} x_{j_{n_1}} \\ y_{j_{n_1}} \\ 1 \end{pmatrix}$$

- По наблюдениям $\begin{pmatrix} x_{i_1} \\ y_{i_1} \end{pmatrix}, \begin{pmatrix} x_{i_2} \\ y_{i_2} \end{pmatrix}, \dots, \begin{pmatrix} x_{i_{n_0}} \\ y_{i_{n_0}} \end{pmatrix}$, которые являются реализацией повторной выборки из распределения $(X, Y)^T$ при условии $Z = 0$, тестом $\varphi^{\text{Independence}}$ (из [разд. 1.5](#)) уровня γ проверим гипотезу $H_0 : X$ и Y независимы при условии $Z = 0$. Если подвыборка не содержит наблюдений, то применяем тест $\varphi \equiv \gamma$.
- По наблюдениям $\begin{pmatrix} x_{j_1} \\ y_{j_1} \end{pmatrix}, \begin{pmatrix} x_{j_2} \\ y_{j_2} \end{pmatrix}, \dots, \begin{pmatrix} x_{j_{n_1}} \\ y_{j_{n_1}} \end{pmatrix}$, которые являются реализацией повторной выборки из распределения $(X, Y)^T$ при условии $Z = 1$, тестом $\varphi^{\text{Independence}}$ (из [разд. 1.5](#)) уровня γ проверим гипотезу $H_1 : X$ и Y независимы при условии $Z = 1$. Если подвыборка не содержит наблюдений, то применяем тест $\varphi \equiv \gamma$.
- Для проверки гипотезы $H : X \perp\!\!\!\perp Y \mid Z$ используем тест объединения-пересечения [10]:

$$\varphi^{\text{Subsamples}} = \begin{cases} 1, & \text{наступило событие } A_0 \cup A_1 \\ 0, & \text{иначе} \end{cases}$$

где $A_0 = \{\text{гипотеза } H_0 \text{ отвергнута}\}$, $A_1 = \{\text{гипотеза } H_1 \text{ отвергнута}\}$.

Замечание 1.6.1. Очевидно, что события A_0 и A_1 независимы. Поэтому для контроля $P_H(\varphi^{\text{Subsamples}} = 1) = \alpha$ достаточно положить $\gamma = 1 - \sqrt{1 - \alpha}$.

Замечание 1.6.2. Использование в вышеприведенной процедуре теста $\varphi^{\text{Independence}}$ объясняется тем, что случайный вектор $(X, Y)^T$ при условии $Z = z$ имеет двумерное распределение Бернулли [4].

2 Экспериментальная часть

2.1 Способ вычисления вероятностей для РНМН теста на ЭВМ

При нахождении порогов для РНМН тестов (см. [разд. 1.4](#), [разд. 1.5](#)) возникает необходимость подсчета вероятностей вида:

$$P_{\theta=0}(U = u \mid T = t) = \frac{(\prod_{i=1}^p k_i(u)!)^{-1}}{\sum_{s \in \mathcal{D}} (\prod_{i=1}^p k_i(s)!)^{-1}}$$

где \mathcal{D} – некая область допустимых значений, $k_i(u) : \mathcal{D} \rightarrow \{0, \dots, n\}$. Основную проблему в этой формуле представляют факториалы, вычисление которых затруднительно на ЭВМ. Предложим методологию, которая поможет обойти эту проблему.

Пусть $f(i) = \sum_{j=1}^i \ln(j)$. Тогда $\ln(n!) = f(n)$. Учитывая это, запишем:

$$\begin{aligned} \frac{(\prod_{i=1}^p k_i(u)!)^{-1}}{\sum_{s \in \mathcal{D}} (\prod_{i=1}^p k_i(s)!)^{-1}} &= \frac{\exp\{-\ln(\prod_{i=1}^p k_i(u)!) \}}{\sum_{s \in \mathcal{D}} \exp\{-\ln(\prod_{i=1}^p k_i(s)!) \}} = \\ &= \frac{\exp\{-\sum_{i=1}^p f(k_i(u)) \}}{\sum_{s \in \mathcal{D}} \exp\{-\sum_{i=1}^p f(k_i(s)) \}} \end{aligned}$$

Полученное выражение удобно с позиции того, что оно не требует подсчета факториалов и ЭВМ умеют эффективно вычислять функцию softmax [2]:

$$\text{softmax}(x, i) = \frac{\exp\{x_i\}}{\sum_{j=1}^N \exp\{x_j\}}, \quad x = (x_1, \dots, x_N)$$

Это происходит благодаря свойству:

$$\text{softmax}(x, i) = \frac{\exp\{x_i\}}{\sum_{j=1}^N \exp\{x_j\}} = \frac{\exp\{x_i - C\}}{\sum_{j=1}^N \exp\{x_j - C\}}, \quad \text{где } C = \max_{1 \leq j \leq N} x_j$$

за счет которого удастся избежать переполнения вещественного типа данных, связанного с вычислением экспоненты.

2.2 Анализ свойств построенных тестов

В данном разделе в трехмерном распределении Бернулли будут анализироваться свойства следующих тестов:

1. φ^{Theta} – РНМН тест уровня $\alpha = 0.05$ проверки гипотезы $H^{\text{Theta}} : \theta = 0$ против альтернативы $K^{\text{Theta}} : \theta \neq 0$, где $\theta = \ln \left(\frac{p_{001}p_{111}p_{010}p_{100}}{p_{011}p_{101}p_{000}p_{110}} \right)$. Отвержение гипотезы H^{Theta} приводит к выводу о том, что в случайном векторе $(X, Y, Z)^T$ все пары случайных величин условно зависимые.
2. $\varphi^{\text{Subsamples}}$ – тест уровня $\alpha = 0.05$ проверки гипотезы $H : X \perp\!\!\!\perp Y \mid Z$.
3. φ^{Partial} – тест уровня $\alpha = 0.05$ проверки гипотезы $H^{\text{Partial}} : \rho^{XY \cdot Z} = 0$, обоснованный для трехмерного нормального распределения. Нами исследуются свойства этого теста в трехмерном распределении Бернулли. Отвержение гипотезы H^{Partial} приводит к выводу о том, что в $(X, Y, Z)^T$ случайные величины X и Y условно зависимы при условии Z .

Для генерации наблюдений из $(X, Y, Z)^T$ с трехмерным распределением Бернулли используется функция `np.random.choice` из пакета NumPy для языка программирования Python.




Рис. 1: Графики зависимости вероятности ошибки 1 рода (O1P) от количества наблюдений, $p_{000} = 0.125, p_{001} = 0.125, p_{010} = 0.125, p_{011} = 0.125, p_{100} = 0.125, p_{101} = 0.125, p_{110} = 0.125, p_{111} = 0.125$. Гипотезы $H : X \perp\!\!\!\perp Y \mid Z$, $H^{\text{Theta}} : \theta = 0$, $H^{\text{Partial}} : \rho^{XY \cdot Z} = 0$ верны. Вероятность оценивается по 10^5 экспериментам.




Рис. 2: Графики зависимости вероятности ошибки 1 рода (OIP) от количества наблюдений, $p_{000} = 0.15, p_{001} = 0.1, p_{010} = 0.3, p_{011} = 0.1, p_{100} = 0.05, p_{101} = 0.1, p_{110} = 0.1, p_{111} = 0.1$. Гипотезы $H : X \perp\!\!\!\perp Y \mid Z$, $H^{Theta} : \theta = 0$, $H^{Partial} : \rho^{XY \cdot Z} = 0$ верны. Вероятность оценивается по 10^5 экспериментам.




Рис. 3: График зависимости мощности от количества наблюдений, $p_{000} = 0.15, p_{001} = 0.1, p_{010} = 0.1, p_{011} = 0.15, p_{100} = 0.1, p_{101} = 0.15, p_{110} = 0.15, p_{111} = 0.1$. Гипотезы $H : X \perp\!\!\!\perp Y \mid Z$, $H^{Theta} : \theta = 0$ не верны. Гипотеза $H^{Partial} : \rho^{XY \cdot Z} = 0$ верна. Мощность оценивается по 10^5 экспериментам.

Из (рис. 1) и (рис. 2) видно, что тесты φ^{Theta} и $\varphi^{Subsamples}$ контролируют вероятность ошибки первого рода на уровне $\alpha = 0.05$ для проверяемых гипотез $H : X \perp\!\!\!\perp Y \mid Z$ и $H^{Theta} : \theta = 0$ соответственно. Этот результат полностью согласуется с теорией из [разд. 1.4](#), [разд. 1.6](#).

(рис. 1), (рис. 2), (рис. 3) показывают, что тест $\varphi^{Partial}$ контролирует вероятность ошибки первого рода на уровне $\alpha = 0.05$ для гипотезы $H^{Partial} : \rho^{XY \cdot Z} = 0$ в трехмерном распределении Бернулли. Этот результат является неожиданным, поскольку тест $\varphi^{Partial}$ теоретически обоснован лишь для трехмерного нормального распределения. Также стоит отметить,

что на (рис. 1), (рис. 2), (рис. 3) показаны ситуации, в которых верна гипотеза $H^{\text{Partial}} : \rho^{XY \cdot Z} = 0$, но гипотеза $H : X \perp\!\!\!\perp Y \mid Z$ как верна (см. (рис. 1) и (рис. 2)), так и не верна (см. (рис. 3)). Поэтому принятие гипотезы $H^{\text{Partial}} : \rho^{XY \cdot Z} = 0$ не приводит к выводам касательно истинности гипотезы $H : X \perp\!\!\!\perp Y \mid Z$.




Рис. 4: График зависимости мощности от количества наблюдений,

$p_{000} = 0.15, p_{001} = 0.06, p_{010} = 0.3, p_{011} = 0.16, p_{100} = 0.05, p_{101} = 0.08, p_{110} = 0.1, p_{111} = 0.1$. Гипотезы $H : X \perp\!\!\!\perp Y \mid Z$, $H^{\text{Theta}} : \theta = 0$, $H^{\text{Partial}} : \rho^{XY \cdot Z} = 0$ не верны, однако X и Y независимы при условии $Z = 0$. Мощность оценивается по 10^5 экспериментам.




Рис. 5: График зависимости мощности от количества наблюдений,

$p_{000} = 0.03, p_{001} = 0.1, p_{010} = 0.04, p_{011} = 0.08, p_{100} = 0.3, p_{101} = 0.1, p_{110} = 0.07, p_{111} = 0.28$. Гипотезы $H : X \perp\!\!\!\perp Y \mid Z$, $H^{\text{Theta}} : \theta = 0$, $H^{\text{Partial}} : \rho^{XY \cdot Z} = 0$ не верны. Мощность оценивается по 10^5 экспериментам.




Рис. 6: График зависимости мощности от количества наблюдений, $p_{000} = 0.21, p_{001} = 0.12, p_{010} = 0.04, p_{011} = 0.34, p_{100} = 0.1, p_{101} = 0.12, p_{110} = 0.02, p_{111} = 0.05$. Гипотезы $H : X \perp\!\!\!\perp Y \mid Z, H^{Theta} : \theta = 0, H^{Partial} : \rho^{XY \cdot Z} = 0$ не верны. Мощность оценивается по 10^5 экспериментам.

Отвержение гипотез, проверяемых тестами φ^{Theta} , $\varphi^{Subsamples}$, $\varphi^{Partial}$, влечет за собой решение о том, что X и Y условно зависимы при условии Z . (рис. 3), (рис. 4), (рис. 5), (рис. 6) показывают что при зависимости X и Y при условии Z тест $\varphi^{Subsamples}$ оказывается мощнее теста $\varphi^{Partial}$. (рис. 5) показывает, что мощность теста $\varphi^{Partial}$ зависит от истинного значения частного коэффициента корреляции Пирсона. Кроме того, из (рис. 5) видно, что при небольшом значении частного коэффициента корреляции Пирсона тесты φ^{Theta} , $\varphi^{Subsamples}$ демонстрируют высокую мощность. Эти факты ставят под сомнение целесообразность использования на практике теста $\varphi^{Partial}$.

Стоит отметить, что при идентификации 0-1 графической модели по наблюдениям возникает необходимость множественной проверки гипотез $H : X \perp\!\!\!\perp Y \mid Z, H' : X \perp\!\!\!\perp Z \mid Y, H'' : Y \perp\!\!\!\perp Z \mid X$. (рис. 3) и (рис. 5) показывают, что в некоторых случаях тест φ^{Theta} , устанавливающий условную зависимость всех пар случайных величин, оказывается мощнее теста $\varphi^{Subsamples}$, устанавливающего условную зависимость одной пары случайных величин. Этот факт приводит к следующему способу идентификации графической модели. Сначала проверяется гипотеза $H^{Theta} : \theta = 0$. В случае её отвержения принимается условная зависимость всех пар случайных величин. А в случае принятия гипотезы H^{Theta} осуществляется дополнительная проверка гипотез H, H' и H'' тестом $\varphi^{Subsamples}$.

Заключение

В настоящей выпускной квалификационной работы были получены следующие результаты:

1. Сформулирован и доказан критерий условной независимости в трехмерном распределении Бернулли.
2. Доказано, что ненулевое значение частного коэффициента корреляции Пирсона $\rho^{XY \cdot Z}$ является достаточным условием условной зависимости X и Y при условии Z в трехмерном распределении Бернулли. Однако, нулевое значение $\rho^{XY \cdot Z}$ не позволяет сделать выводы об условной независимости или зависимости.
3. Эмпирически, при объеме наблюдений $50 \leq n \leq 300$, показано, что тест φ^{Partial} является тестом уровня α проверки гипотезы $H^{\text{Partial}} : \rho^{XY \cdot Z} = 0$ против альтернативы $K^{\text{Partial}} : \rho^{XY \cdot Z} \neq 0$ в трехмерном распределении Бернулли.
4. В экспоненциальной форме записи трехмерного распределения Бернулли найден параметр $\theta = \ln \left(\frac{p_{001}p_{111}p_{010}p_{100}}{p_{011}p_{101}p_{000}p_{110}} \right)$, ненулевое значение которого является достаточным условием условной зависимости всех пар случайных величин. При нулевом значении параметра θ требуются дополнительные исследования условных зависимостей в случайном векторе.
5. Построен РНМН-тест φ^{Theta} уровня α проверки гипотезы $H^{\text{Theta}} : \theta = 0$ против альтернативы $K^{\text{Theta}} : \theta \neq 0$.
6. Построен тест $\varphi^{\text{Subsamples}}$ уровня α проверки гипотезы $H : X \perp\!\!\!\perp Y \mid Z$.

Список литературы

1. *Anderson T.* An Introduction to Multivariate Statistical Analysis. — Wiley-Interscience, 2003.
2. *Blanchard P., Higham D. J., Higham N. J.* Accurately computing the log-sum-exp and softmax functions // IMA Journal of Numerical Analysis. — 2020. — Т. 41, № 4. — С. 2311—2330.
3. *Cramér H.* Mathematical methods of statistics. — Princeton University Press, 1946.
4. *Dai B., Ding S., Wahba G.* Multivariate Bernoulli distribution // Bernoulli. — 2013. — Т. 19, № 4. — С. 1465—1483.
5. *Drton M., Perlman M. D.* Model selection for Gaussian concentration graphs // Biometrika. — 2004. — Т. 91, № 3. — С. 591—602.
6. *Drton M., Perlman M. D.* Multiple testing and error control in Gaussian graphical model selection // Statistical Science. — 2007. — Т. 22, № 3. — С. 430—449.
7. *Jordan M. I.* Graphical Models // Statistical Science. — 2004. — Т. 19, № 1. — С. 140—155.
8. *Lauritzen S. L.* Graphical models. — Clarendon Press, 1996.
9. *Lehmann E. L.* Testing statistical hypotheses. — Wiley, 1986.
10. *Roy S. N.* On a Heuristic Method of Test Construction and its use in Multivariate Analysis // The Annals of Mathematical Statistics. — 1953. — Т. 24, № 2. — С. 220—238.
11. *Teugels J. L.* Some representations of the multivariate Bernoulli and binomial distributions // Journal of Multivariate Analysis. — 1990. — Т. 32, № 2. — С. 256—268.
12. *Wille A., Bühlmann P.* Low-Order Conditional Independence Graphs for Inferring Genetic Networks // Statistical Applications in Genetics and Molecular Biology. — 2006. — Т. 5, № 1.